

Classificação de Tumores Cerebrais: Uma Abordagem Baseada em Redes Neurais Convolucionais e Transfer Learning

Túlio Baruk Melo Silva¹, Thiago Jorge Lins da Hora¹,
Luciano de Souza Cabral¹

¹Instituto Federal de Educação, Ciência e Tecnologia de Pernambuco
(IFPE) – Jaboatão dos Guararapes – Pernambuco – Brasil

{tbms,tjlh}@discente.ifpe.edu.br, luciano.cabral@jaboatao.ifpe.edu.br

Abstract. *This study explores the use of convolutional neural networks (CNNs) combined with transfer learning techniques for the classification of brain tumors using MRI images. Leveraging pre-trained models such as EfficientNetB0, InceptionV3, and VGG19, along with a custom 5-layer CNN, the research aims to enhance the accuracy and efficiency of tumor classification. The results demonstrate that EfficientNetB0 and InceptionV3 models achieved the highest performance, with both reaching 97% accuracy, precision, recall, and F1-score. These findings highlight the potential of advanced CNN architectures in improving early diagnosis and aiding treatment planning, underscoring their utility as promising tools in clinical settings.*

Resumo. *Este estudo explora o uso de redes neurais convolucionais (CNNs) combinadas com técnicas de transferência de aprendizado para a classificação de tumores cerebrais utilizando imagens de ressonância magnética (MRI). Aproveitando modelos pré-treinados como EfficientNetB0, InceptionV3 e VGG19, além de uma CNN personalizada de 5 camadas convolucionais, a pesquisa visa aprimorar a precisão e eficiência da classificação de tumores. Os resultados demonstram que os modelos EfficientNetB0 e InceptionV3 alcançaram o melhor desempenho, com ambos atingindo 97% de acurácia, precisão, revocação e F1-score. Esses achados destacam o potencial das arquiteturas avançadas de CNN para melhorar o diagnóstico precoce e auxiliar no planejamento do tratamento, sublinhando sua utilidade como ferramentas promissoras em ambientes clínicos.*

1. Introdução

Os tumores cerebrais representam uma das condições médicas mais desafiadoras devido à sua complexidade e à importância do diagnóstico precoce para o sucesso do tratamento "Inteligência artificial pode melhorar a qualidade da neuroimagem e reduzir as cargas clínicas e sistêmicas de outras modalidades de imagem"[Monsour et al. 2022]. A análise de imagens de ressonância magnética (MRI) é essencial para a identificação e classificação de tumores cerebrais, proporcionando uma avaliação detalhada das características morfológicas e fisiológicas dos tecidos. Essa técnica avançada permite uma visualização precisa da localização, tamanho e extensão dos tumores, facilitando a distinção entre diferentes tipos de lesões.

Nos últimos anos, técnicas de aprendizado profundo, especialmente redes neurais convolucionais (CNN), têm mostrado grande potencial na análise de imagens médicas "A IA tem mostrado capacidade significativa para melhorar a precisão da localização de tumores, aumentando a eficiência para os radiologistas e reduzindo o potencial de erro humano"[Sun et al. 2019]. As CNNs são capazes de capturar características complexas das imagens, tornando-se uma ferramenta poderosa para a classificação de tumores cerebrais. Neste estudo, utilizamos técnicas de transferência de aprendizado para melhorar a precisão da classificação, aproveitando modelos pré-treinados em grandes conjuntos de dados como o ImageNet.

Este artigo explora o uso de CNNs combinadas com transferência de aprendizado na classificação de quatro categorias: glioma, meningioma, adenoma pituitário (pituitary tumor) e ausência de tumor. A abordagem proposta visa fornecer um método eficiente e preciso para auxiliar no diagnóstico clínico.

2. Trabalhos Relacionados

O uso de Redes Neurais Convolucionais (CNNs) para a classificação de tumores cerebrais a partir de imagens de ressonância magnética (MRI) tem sido amplamente explorado na literatura recente, demonstrando avanços significativos na precisão diagnóstica e na eficiência computacional.

[Felipe et al. 2023] desenvolveu um novo modelo de rede neural convolucional (CNN) especificamente para a classificação de tumores cerebrais a partir de imagens de ressonância magnética (MRI). Este modelo foi treinado em um grande conjunto de dados e demonstrou um desempenho notável, alcançando uma precisão geral de 99% no conjunto de testes. O estudo destacou a eficácia das CNNs no diagnóstico de tumores cerebrais, superando métodos tradicionais e alguns modelos de ponta existentes, sugerindo que técnicas avançadas de aprendizado profundo podem fornecer melhorias significativas na classificação de imagens médicas.

Outro estudo relevante é o de [Modaresnia et al. 2023], que propôs uma abordagem híbrida utilizando EfficientNetB0 para a classificação de tumores cerebrais a partir de imagens de ressonância magnética (MRI). Neste trabalho, foram utilizadas técnicas de transferência de aprendizado para ajustar o EfficientNetB0, seguido pelo uso de um classificador de árvores de decisão por bagging, o que resultou em uma precisão média de 99.64%. Essa abordagem combinada superou modelos de ponta anteriores, demonstrando a eficácia do uso de aprendizado profundo e métodos de aprendizado de máquina tradicionais na classificação de tumores cerebrais.

O estudo de [Khaliki and Başarslan 2024] realizou uma comparação detalhada entre métodos de aprendizado por transferência e uma CNN de três camadas para a detecção de tumores cerebrais a partir de imagens de ressonância magnética (MRI). Utilizando modelos baseados em CNN como InceptionV3, EfficientNetB4, VGG16 e VGG19, o estudo avaliou a eficácia de diferentes técnicas de aprendizado profundo na classificação de tumores cerebrais. Os resultados indicaram que o modelo VGG16 alcançou a maior precisão, com 98%, destacando a importância de arquiteturas de aprendizado por transferência em aplicações médicas. Este trabalho enfatiza o papel crucial de técnicas avançadas de aprendizado de máquina na melhoria do diagnóstico e tratamento de tumores cerebrais, contribuindo para uma melhor compreensão das melhores práticas para

a classificação de imagens médicas.

Esses estudos fornecem uma base sólida para o uso de técnicas de aprendizado profundo na classificação de tumores cerebrais, evidenciando que tanto as CNNs tradicionais quanto as abordagens híbridas com aprendizado por transferência têm um potencial significativo para aprimorar os resultados diagnósticos. No contexto deste trabalho, adota-se uma abordagem que combina o poder das CNNs com técnicas de transferência de aprendizado e pré-processamento de dados, com o objetivo de melhorar a precisão e a eficiência na classificação de diferentes tipos de tumores cerebrais. Esta estratégia visa contribuir para a evolução contínua das metodologias de aprendizado profundo aplicadas à medicina, facilitando diagnósticos mais precisos e intervenções mais rápidas em um cenário clínico.

3. Metodologia

Este estudo foi realizado utilizando imagens de ressonância magnética (MRI) da base de dados pública disponível no Kaggle, intitulada "Brain Tumor Classification (MRI)" [Bhuvaji et al. 2020]. O dataset contém um total de 3264 imagens divididas em quatro categorias: glioma, meningioma, adenoma pituitário (pituitary tumor) e imagens sem evidência de tumor.




Figura 1. Exemplo de imagens e classes do dataset

As imagens foram obtidas de diferentes modalidades de ressonância magnética, incluindo T1-weighted, T2-weighted e FLAIR, permitindo uma análise abrangente das características morfológicas dos tumores.

3.1. Pré-processamento dos Dados

Cada imagem foi redimensionada para 150x150 pixels para padronização para os modelos EfficientNetB0, InceptionV3 e a CNN personalizada. No caso do modelo VGG19, as imagens foram redimensionadas para 224x224 pixels. Utilizamos a biblioteca OpenCV para leitura e pré-processamento das imagens, que incluiu redimensionamento e normalização (divisão dos valores dos pixels por 255 para converter os dados para uma faixa de 0 a 1) apenas para os modelos InceptionV3 e a CNN personalizada. A normalização foi desativada para os modelos VGG19 e EfficientNetB0, que não requerem essa etapa. Os dados foram, então, divididos em conjuntos de treinamento e teste utilizando uma divisão estratificada com 80% para treinamento e 20% para teste.

3.2. Modelos Utilizados e Transfer Learning

Desenvolvemos múltiplos modelos de redes neurais convolucionais (CNNs) para realizar a classificação das imagens nas categorias específicas. O modelo inicial foi estruturado com várias camadas convolucionais (5 camadas convolucionais), seguidas por camadas de pooling e camadas totalmente conectadas. Além disto, foram avaliadas diferentes arquiteturas, incluindo EfficientNetB0, InceptionV3 e VGG19, todas pré-treinadas no dataset ImageNet e posteriormente refinadas (*fine-tuning*) para adaptação ao nosso conjunto de dados. Para o modelo VGG19, foi aplicada uma regularização L2 em uma das camadas densas para melhorar a generalização. A função de perda utilizada durante o treinamento foi a `categorical_crossentropy`, enquanto a métrica de desempenho adotada para a avaliação dos modelos foi a acurácia.




Figura 2. Arquitetura CNN - VisualKeras

O treinamento dos modelos foi realizado com um conjunto de dados ampliado e validado utilizando o método *Early Stopping* para prevenir overfitting, monitorando a perda na validação. O aprendizado foi regulado com o callback `ReduceLROnPlateau`, que reduziu a taxa de aprendizado quando a métrica parou de melhorar.

4. Resultados e Discussão

Os resultados dos modelos são apresentados na Tabela 1, com destaque para a acurácia, precisão, revocação e F1-score.

Os resultados apresentados na Tabela 1 destacam o desempenho de quatro modelos de redes neurais convolucionais (CNNs) para a classificação de tumores cerebrais

Modelo	Acurácia	Precisão	Revocação	F1-score
5Layer CNN	0.93	0.93	0.92	0.93
InceptionV3	0.97	0.97	0.97	0.97
VGG19	0.81	0.79	0.82	0.80
EfficientNetB0	0.97	0.97	0.97	0.97

Tabela 1. Avaliação dos modelos para classificação de tumores cerebrais.

em imagens de ressonância magnética (MRI). Entre os modelos testados, o InceptionV3 e o EfficientNetB0 alcançaram as melhores performances, com uma acurácia, precisão, revocação e F1-score de 97%. Esses resultados indicam que ambos os modelos são altamente eficazes na distinção entre as diferentes classes de tumores, sugerindo que as arquiteturas de redes mais avançadas e complexas têm uma capacidade superior de capturar as características distintivas das imagens de MRI.

O modelo 5Layer CNN, com cinco camadas convolucionais, também obteve bons resultados, com uma acurácia de 93% e um F1-score de 93%. Embora sua performance seja ligeiramente inferior à dos modelos pré-treinados e mais sofisticados, ele ainda demonstra uma capacidade considerável para a tarefa de classificação de imagens de tumores cerebrais.

Por outro lado, o modelo VGG19 apresentou um desempenho significativamente inferior, com uma acurácia de 81% e métricas de precisão, revocação e F1-score correspondentes. Esse resultado pode indicar que, embora o VGG19 seja uma arquitetura poderosa, sua performance é menos robusta neste contexto específico de classificação de tumores cerebrais. Possíveis razões para esse desempenho podem incluir uma necessidade de mais dados para treinamento eficaz, ajuste de hiperparâmetros ou técnicas de pré-processamento mais adequadas.

No geral, os resultados sugerem que modelos de CNN mais recentes e avançados, como o InceptionV3 e EfficientNetB0, são mais adequados para tarefas de classificação complexas em imagens médicas. No entanto, o uso de modelos menos complexos, como o 5Layer CNN, pode ser justificado em cenários onde a computação é uma restrição, dada a sua eficácia relativa.

5. Considerações Finais

Este estudo demonstrou a eficácia de várias arquiteturas de redes neurais convolucionais (CNNs) na tarefa de classificação de tumores cerebrais utilizando imagens de ressonância magnética (MRI). Os modelos EfficientNetB0 e InceptionV3 se destacaram, apresentando os melhores desempenhos em termos de acurácia, precisão, revocação e F1-score, confirmando sua capacidade superior de generalização e robustez na classificação de imagens médicas complexas. Por outro lado, o modelo VGG19 não atingiu resultados comparáveis, possivelmente devido a limitações na sua capacidade de extrair características específicas das imagens de tumores cerebrais ou na necessidade de maior ajuste fino com dados específicos.

Os resultados indicam que a escolha do modelo de aprendizado profundo é crucial para otimizar o diagnóstico de tumores cerebrais. Modelos mais avançados e recentes, especialmente aqueles pré-treinados em grandes conjuntos de dados como o ImageNet, for-

necem uma base sólida para o ajuste fino e melhor desempenho em tarefas específicas do domínio médico. No entanto, modelos menos complexos, como o 5Layer CNN, também mostraram desempenho competitivo, o que pode ser útil em contextos onde recursos computacionais são limitados.

Para futuras pesquisas, recomenda-se explorar técnicas avançadas de *fine-tuning* e incorporar métodos de aprendizado por transferência mais sofisticados. Além disso, aumentar a diversidade e o tamanho do conjunto de dados de treinamento, incluindo diferentes modalidades de imagens de ressonância magnética e dados clínicos adicionais, pode ajudar a melhorar ainda mais a precisão dos modelos. A integração de técnicas de aprendizado multimodal e aprendizado federado também pode ser uma área promissora para desenvolver modelos mais robustos e generalizáveis para aplicações clínicas reais.

Finalmente, é essencial considerar a implementação desses modelos em sistemas de apoio à decisão clínica, onde a precisão e a rapidez do diagnóstico são críticas. A utilização de modelos de aprendizado profundo pode não apenas melhorar a precisão diagnóstica, mas também auxiliar na personalização dos planos de tratamento, contribuindo para melhores resultados de saúde e qualidade de vida dos pacientes.

Referências

- Bhuvaji, S., Kadam, A., Bhumkar, P., Dedge, S., and Kanchan, S. (2020). Brain tumor classification (mri).
- Felipe, C., Alva, T., Winck, A., and Becker, C. (2023). An approach in brain tumor classification: The development of a new convolutional neural network model. In *Anais do XX Encontro Nacional de Inteligência Artificial e Computacional*, pages 28–42, Porto Alegre, RS, Brasil. SBC.
- Khaliki, M. Z. and Başarslan, M. S. (2024). Brain tumor detection from images and comparison with transfer learning methods and 3-layer cnn. *Scientific Reports*, 14:2664.
- Modaresnia, Y., Abedinzadeh, F., and Hosseini, S. A. (2023). Efficientnetb0’s hybrid approach for brain tumor classification from mri images using deep learning and bagging trees. In *Proceedings of the 13th International Conference on Computer and Knowledge Engineering (ICCKE 2023)*, pages 1–8. IEEE.
- Monsour, R., Dutta, M., Mohamed, A., Borkowski, A., and Viswanadhan, N. (2022). Neuroimaging in the era of artificial intelligence: Current applications. *Federal Practitioner*, 39(Suppl 1):S14–S20. Epub 2022 Apr 12.
- Sun, L., Zhang, S., Chen, H., and Luo, L. (2019). Brain tumor segmentation and survival prediction using multimodal mri scans with deep learning. *Frontiers in Neuroscience*, 13:810.